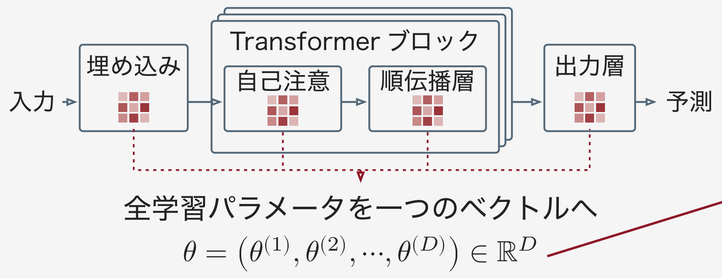
大規模言語モデルにおける進化戦略の適応・中立理論

横井 創磨（早稲田大学・東京大学） 佐藤 一誠（東京大学）

背景 進化戦略による LLM の微調整

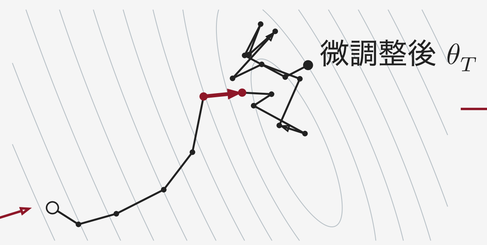
LLM のパラメータ



全学習パラメータを一つのベクトルへ

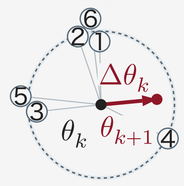
$$\theta = \left(\theta^{(1)}, \theta^{(2)}, \cdots, \theta^{(D)}\right) \in \mathbb{R}^D$$

LLM パラメータの学習軌跡



事前学習済み θ_0　　報酬 R_σ

個体の生成と 1 回の更新



生成する個体

$$\theta_k + \sigma\varepsilon_n$$

方向に偏りのない摂動

$$\varepsilon_n \sim \mathcal{N}(0, I_D)$$

$$\Delta\theta_k = \alpha\hat{g}_N = \frac{\alpha}{\sigma N}\sum_{n=1}^{N} w_n \varepsilon_n$$

報酬値だけで更新 → 逆伝播不要・省メモリ

回答の評価と重み

個体 → 回答 → 採点 R_n

Z スコア：$w_n = \frac{R_n - \text{平均}}{\text{標準偏差}}$



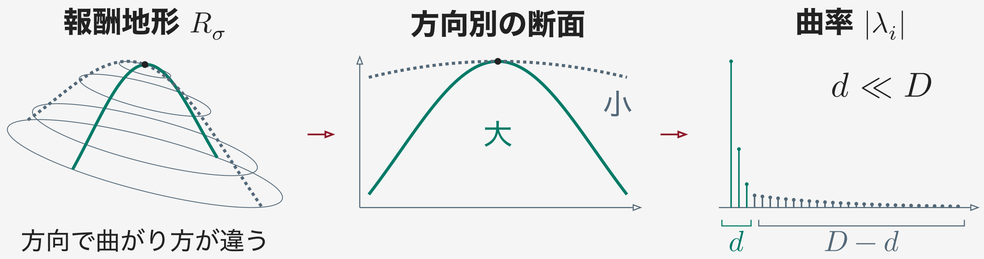
各個体の寄与を足す



先行知見 曲率の偏り

LLM の報酬地形では、
少数方向に曲率が集中する
Liang et al., 2026

方向で曲がり方が違う



問い 2 つの謎

$N = 30$ 個体で、$D \approx 30$ 億の
全パラメータを**学習できる**

学習を続けると、訓練報酬が
低下することがある

定式化 学習の進行と性能変化を統一的に解析する

1 確率微分方程式（SDE）でモデル化

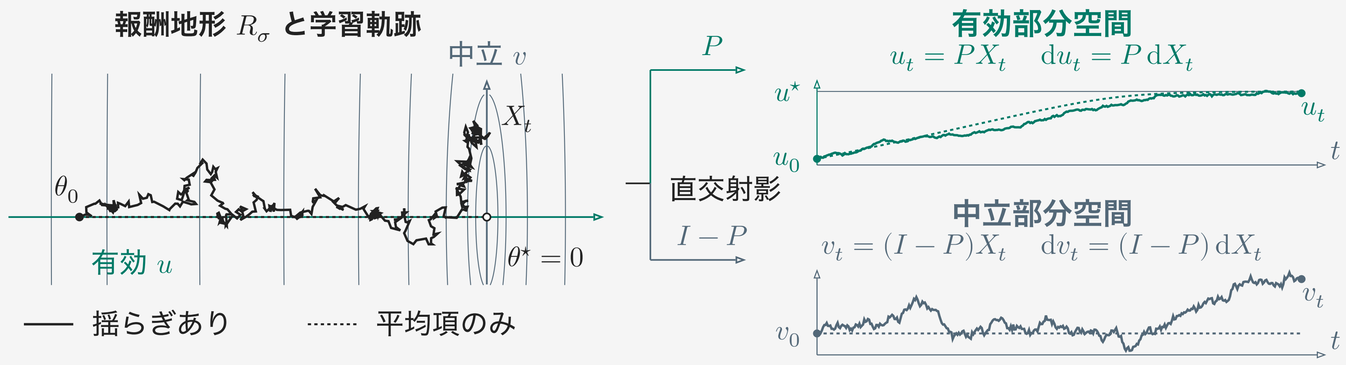
$$\theta_{k+1} = \theta_k + \alpha\hat{g}_N(\theta_k)$$

↓ 連続時間で近似　$X_0 = \theta_0$

$$\mathrm{d}X_t = \underbrace{\alpha b_N(X_t)\,\mathrm{d}t}_{\text{平均}} + \underbrace{\alpha A_N(X_t)\,\mathrm{d}W_t}_{\text{揺らぎ}}$$

$b_N = \mathbb{E}\hat{g}_N$、$A_N A_N^\top = \mathrm{Cov}(\hat{g}_N)$
t：反復時間　W_t：標準ブラウン運動

2 曲率に沿って運動を分解

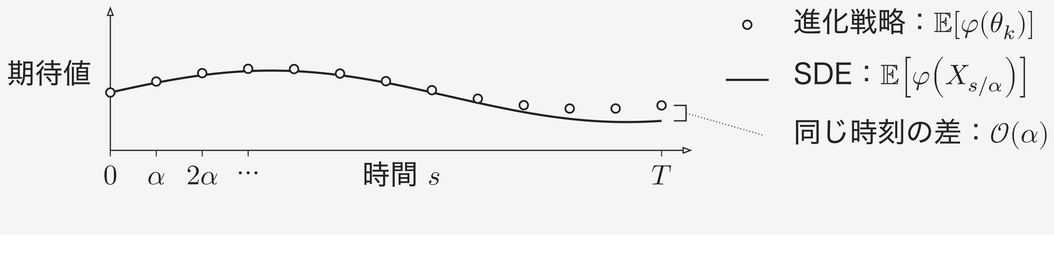


主結果 有限時間の弱近似を保証し、有効方向での学習と中立方向の変動による報酬低下の条件を導出した

定理 1 進化戦略の有限時間弱近似

テスト関数 φ と時刻 T に対して、

$$\max_{0 \le k\alpha \le T} \left|\mathbb{E}[\varphi(\theta_k)] - \mathbb{E}[\varphi(X_k)]\right| = \mathcal{O}(\alpha) \quad (\alpha \to 0).$$



解釈

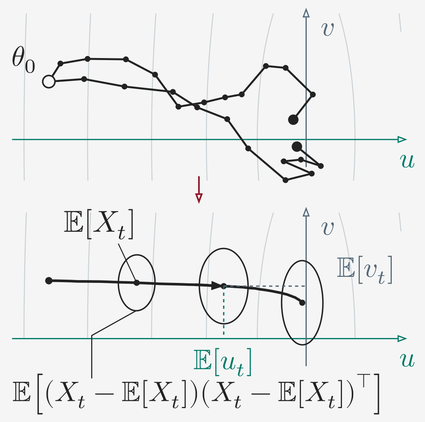
進化戦略の平均・共分散を
SDE で近似できる

↓

曲率に沿って運動を分解し
報酬変化への寄与を調べる

↓

**小個体群での学習と
改善後の性能低下を解析する**



定理 2 小個体群で学習が進む条件

有効方向で平均報酬が増加する十分条件

$$\frac{\alpha}{\sigma}\sqrt{2\mu V_u} \quad > \quad \frac{L\alpha^2}{2\sigma^2}\frac{\boldsymbol{d}}{\boldsymbol{N}} \quad + \quad \bar{r}$$

平均更新による増加の基準
報酬差 V_u・局所 PL 条件 μ

ばらつきによる損失の基準
平滑性 L

係数近似の
補正上界



$d = d_0$　では　$N > N_0 = \dfrac{L\alpha d_0}{2\sigma\left[\sqrt{2\mu V_u} - \left(\frac{\sigma}{\alpha}\right)\bar{r}\right]}$

解釈

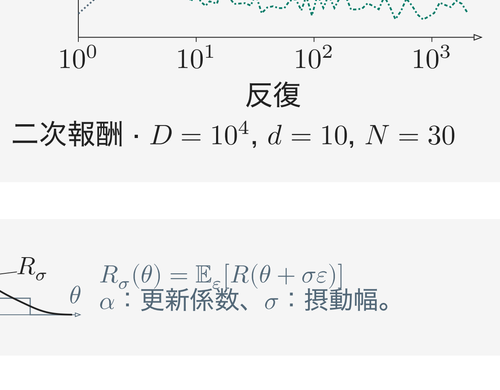
有効次元 d が小さいほど
条件を満たす個体数 N を減らせる

↓

LLM の報酬地形では
全次元 D に比べて d は非常に小さい

↓

**小個体群の進化戦略で
巨大な LLM を学習できる**



定理 3 学習の継続と報酬の低下

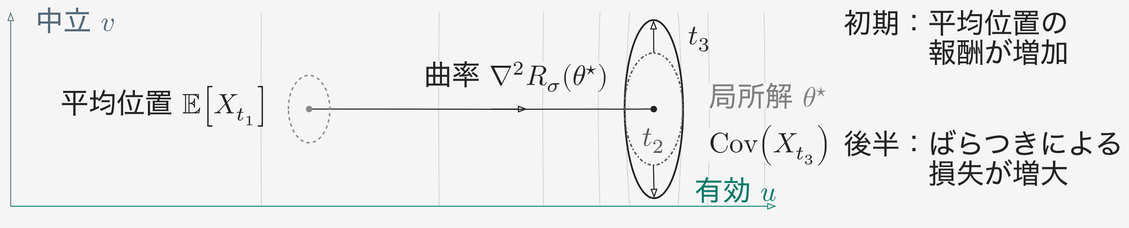
訓練報酬 R_σ の平均が増加する十分条件 $(t_1 < t_2)$

$$\left[R_\sigma(\mathbb{E}[X_t])\right]_{t_1}^{t_2} \quad > -\frac{1}{2}\left[\mathrm{Tr}\left\{\nabla^2 R_\sigma(\theta^\star)\,\mathrm{Cov}(X_t)\right\}\right]_{t_1}^{t_2} + \quad \varepsilon$$

平均位置での報酬変化

ばらつきによる損失の増分

近似誤差の上界



初期：平均位置の
報酬が増加

後半：ばらつきによる
損失が増大

解釈

有効方向の改善が鈍り、
中立方向への広がりが続く間に

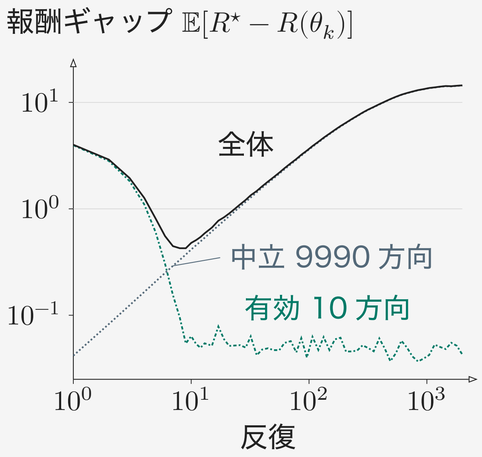
↓

多数の中立方向の損失増の合計が
残る報酬の改善を上回ると

↓

**学習を続けても
期待報酬が低下に転じる**

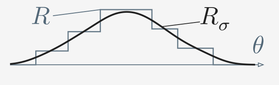
報酬ギャップ $\mathbb{E}[R^\star - R(\theta_k)]$



二次報酬 · $D = 10^4$, $d = 10$, $N = 30$

展望 計算効率のよい微調整と、忘却を抑える継続学習へ

補足



$R_\sigma(\theta) = \mathbb{E}_\varepsilon[R(\theta + \sigma\varepsilon)]$
α：更新係数、σ：摂動幅。