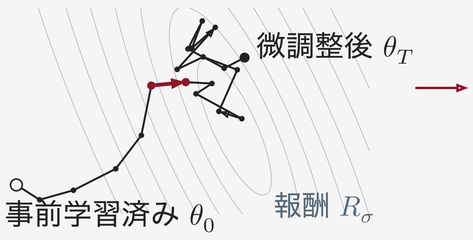
大規模言語モデルにおける進化戦略の適応・中立理論

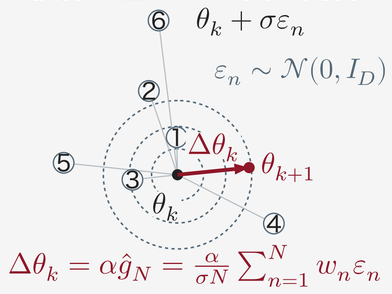
横井創磨・佐藤一誠　　東京大学

前提 進化戦略による LLM の微調整

LLM パラメータの学習軌跡

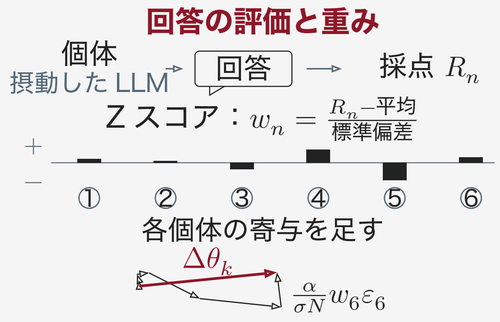


個体の生成と 1 回の更新



$$\Delta\theta_k = \alpha\hat{g}_N = \frac{\alpha}{\sigma N}\sum_{n=1}^{N} w_n\varepsilon_n$$

回答の評価と重み



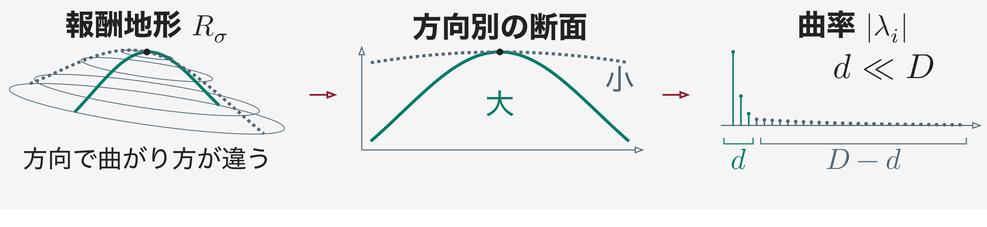
問い

なぜ**少数の個体**で
学習できるのか？
パラメータ $D \approx 30$ 億／1 回の更新に $N = 30$ 個体

なぜ学習を続けると、
性能が下がることがあるのか？
学習で最大化している訓練タスクの報酬

背景 曲率の偏り

LLM の報酬地形では、
少数方向に曲率が集中。
Liang et al., 2026



仮説 方向ごとに運動の役割が異なる

曲率の大きい少数方向で **改善が進み**、
曲率の小さい多数方向に **変動が蓄積する。**

定式化 学習の進行と性能変化を統一的に解析

1 確率微分方程式（SDE）でモデル化

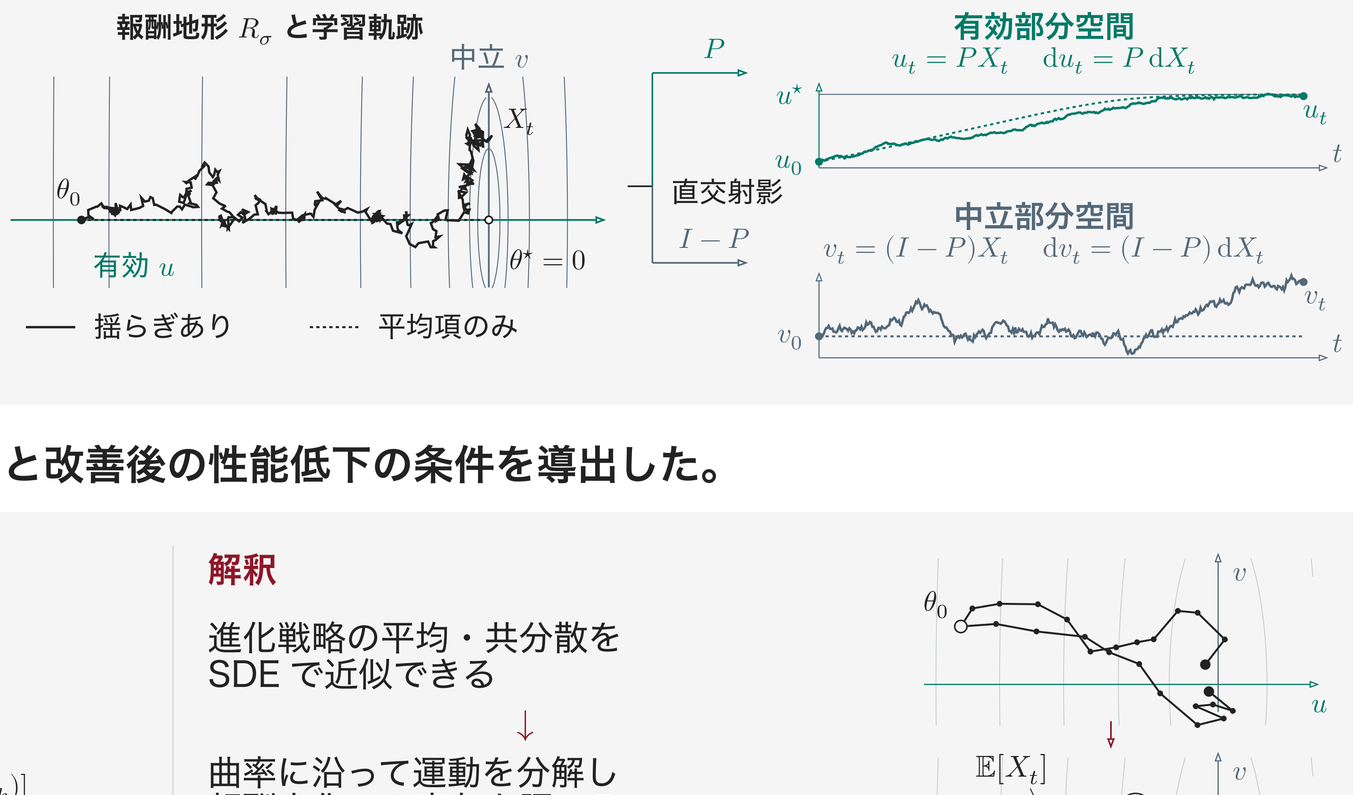
$$\theta_{k+1} = \theta_k + \alpha\hat{g}_N(\theta_k)$$

↓ 連続時間で近似　$X_0 = \theta_0$

$$\mathrm{d}X_t = \underbrace{\alpha b_N(X_t)\,\mathrm{d}t}_{\text{平均}} + \underbrace{\alpha A_N(X_t)\,\mathrm{d}W_t}_{\text{揺らぎ}}$$

$b_N = \mathbb{E}\hat{g}_N$、$A_N A_N^\top = \mathrm{Cov}(\hat{g}_N)$
t：反復時間　W_t：標準ブラウン運動

2 曲率に沿って運動を分解

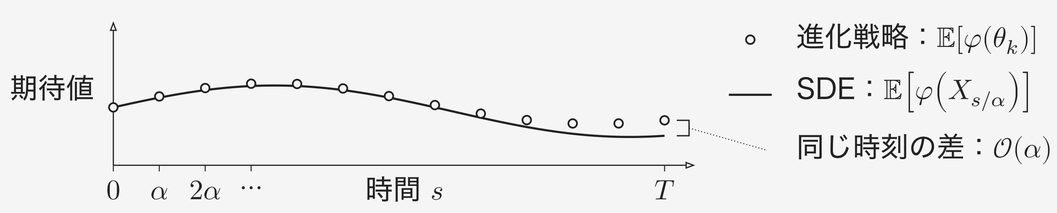


主結果 有限時間の弱近似を保証し、小個体群での学習と改善後の性能低下の条件を導出した。

定理 1 進化戦略の有限時間弱近似

テスト関数 φ と時刻 T に対して、

$$\max_{0 \le k\alpha \le T} |\mathbb{E}[\varphi(\theta_k)] - \mathbb{E}[\varphi(X_k)]| = \mathcal{O}(\alpha) \quad (\alpha \to 0).$$



解釈

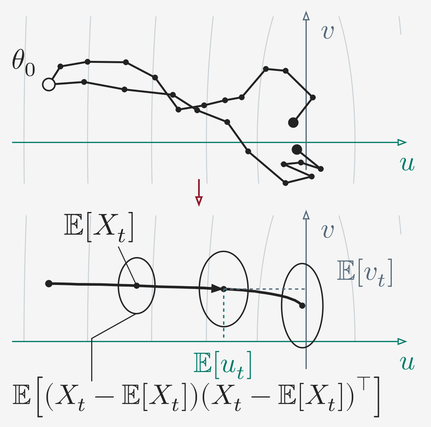
進化戦略の平均・共分散を
SDE で近似できる

↓

曲率に沿って運動を分解し
報酬変化への寄与を調べる

↓

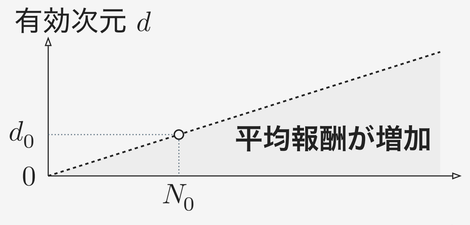
小個体群での学習と
改善後の性能低下を解析する



定理 2 小個体群で学習が進む条件

有効方向で平均報酬が増加する十分条件

$$d < \frac{2\sigma N}{L\alpha}\left[\sqrt{2\mu V_u} - \left(\frac{\sigma}{\alpha}\right)\bar{r}\right]$$



$d = d_0$　では　$N > N_0 = \dfrac{L\alpha d_0}{2\sigma\left[\sqrt{2\mu V_u} - \left(\frac{\sigma}{\alpha}\right)\bar{r}\right]}$

$V_u = R_\sigma(u^*, 0) - R_\sigma(u, 0)$。局所 PL 条件 (μ)・平滑性 (L)、$\bar{r}$：係数近似の補正上界。

解釈

有効次元 d が小さいほど
条件を満たす個体数 N を減らせる

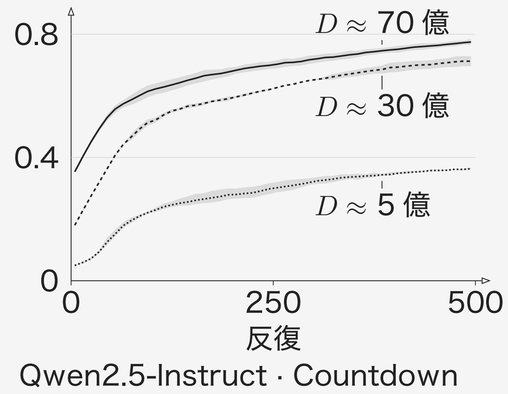
↓

LLM の報酬地形では
全次元 D に比べて d は非常に小さい

↓

小個体群の進化戦略で
巨大な LLM を最適化できる

全パラメータの微調整　$N = 30$
集団平均訓練報酬



Qwen2.5-Instruct · Countdown

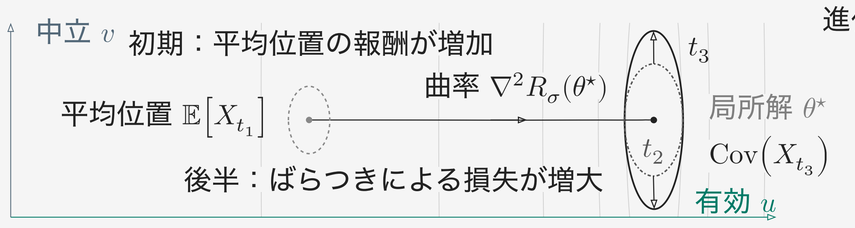
定理 3 学習の継続と報酬の低下

訓練報酬 R_σ の平均が増加する十分条件 $(t_1 < t_2)$

$$[R_\sigma(\mathbb{E}[X_t])]_{t_1}^{t_2} > -\frac{1}{2}\left[\mathrm{Tr}\{\nabla^2 R_\sigma(\theta^\star)\,\mathrm{Cov}(X_t)\}\right]_{t_1}^{t_2} + \varepsilon$$

平均位置での報酬変化　　ばらつきによる損失の増分　　近似誤差の上界

進化戦略・2 次元



解釈

有効方向の改善が鈍り、
中立方向への広がりが続く間に

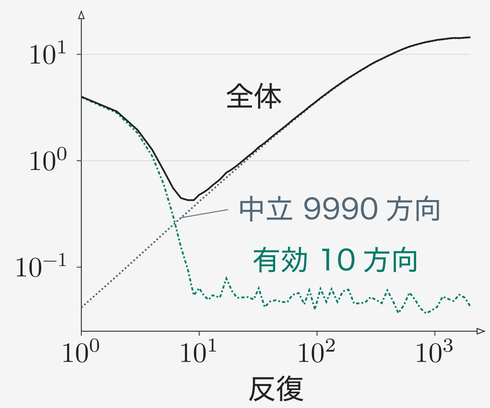
↓

多数の中立方向の損失増の合計が
残る報酬の改善を上回ると

↓

学習を続けても
期待報酬が低下に転じる

報酬ギャップ $\mathbb{E}[R^\star - R(\theta_k)]$



二次報酬 · $D = 10^4$, $d = 10$, $N = 30$

展望 計算効率のよい微調整と、忘却を抑える継続学習へ

補足　α：更新係数、σ：摂動幅。
平滑化報酬 $R_\sigma(\theta) = \mathbb{E}_\varepsilon[R(\theta + \sigma\varepsilon)]$。